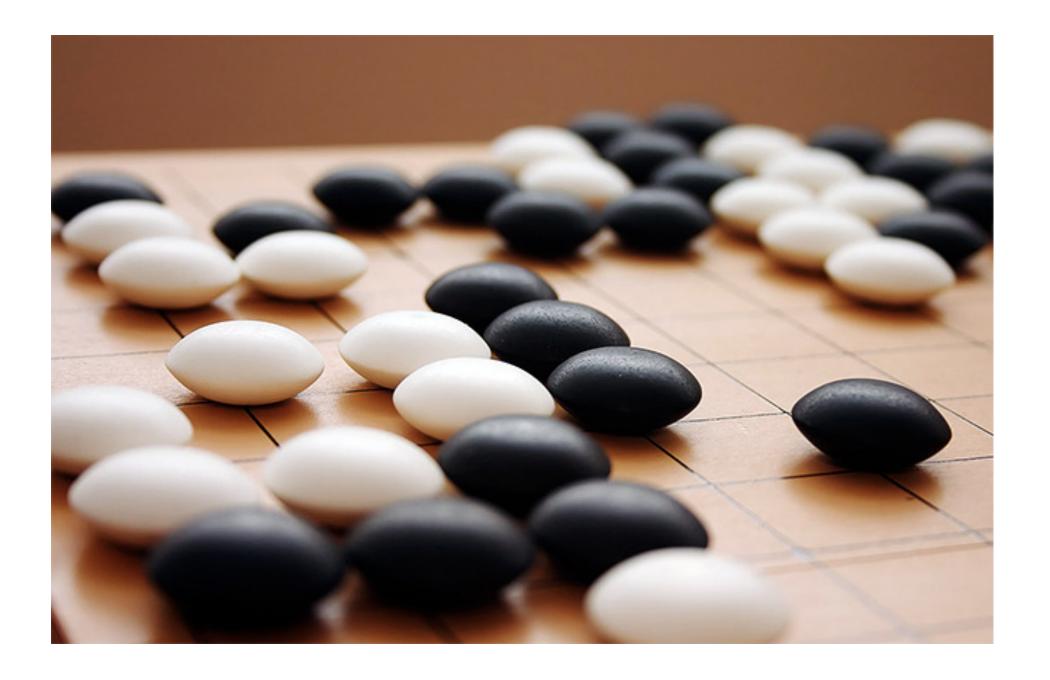
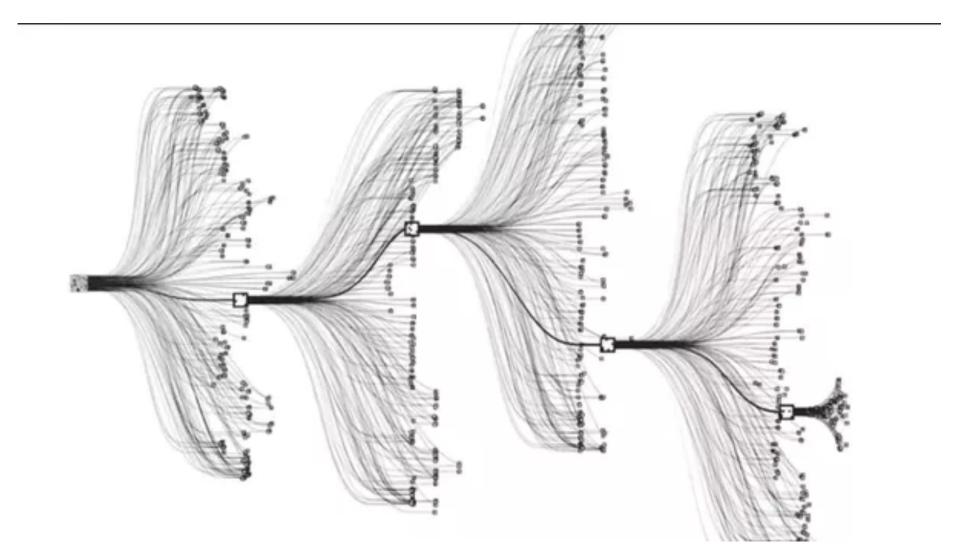
알파고1 논문 리뷰

Mastering the game of Go with deep neural networks and tree search

(D. Silver, A. Huang et al. 네이쳐, 2016)



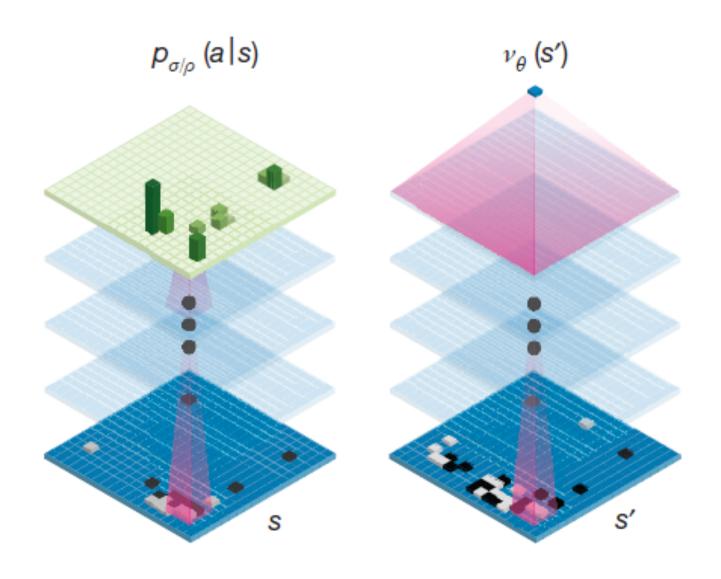
Monte Carlo Tree Search

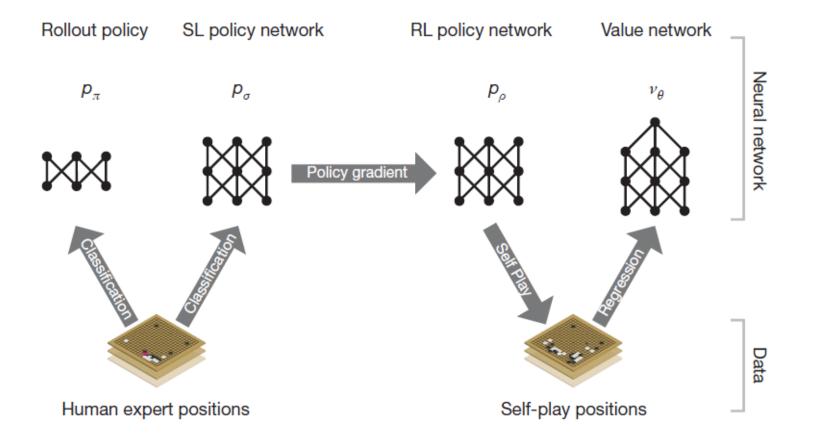


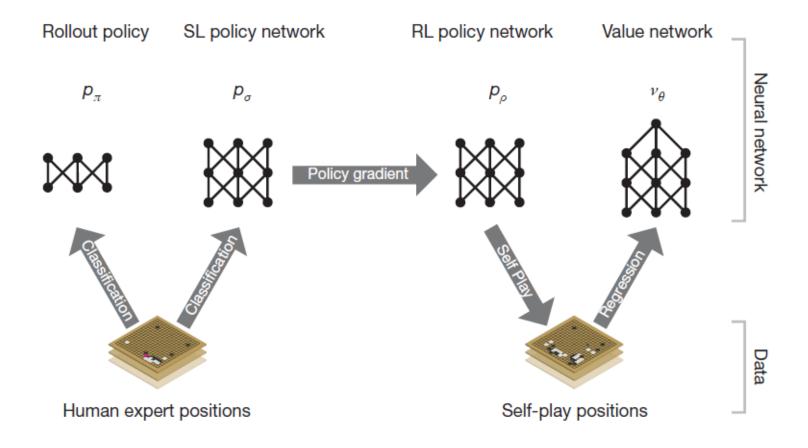
https://blogs.loc.gov/maps/category/game-theory/

Policy network

Value network

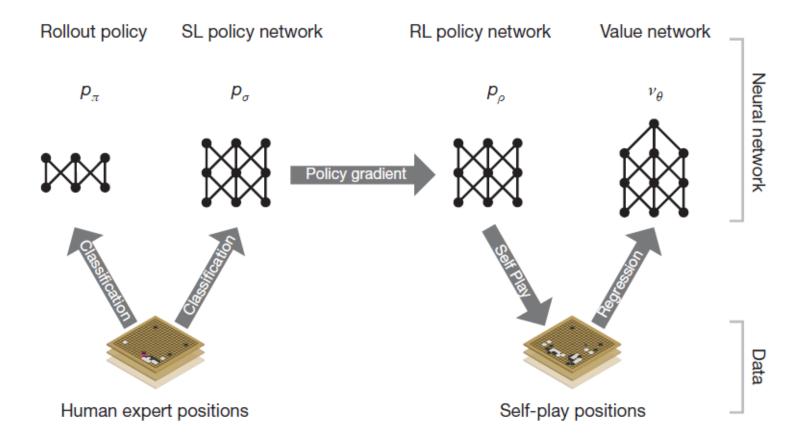






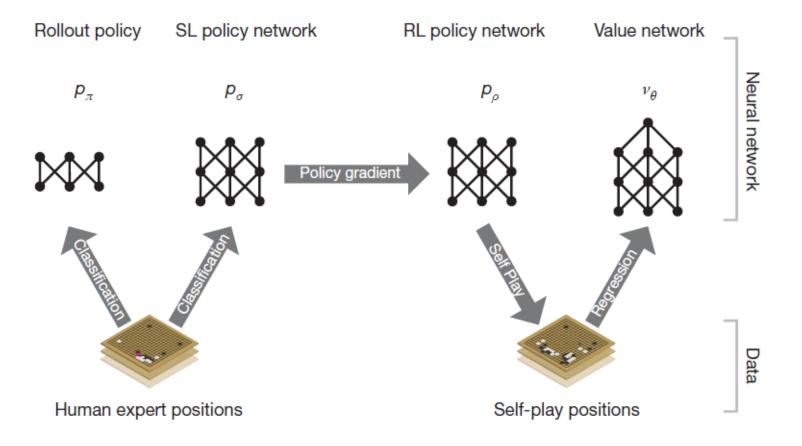
1. SL Policy

- Classification
- 13 레이어의 CNN 학습
- 인풋은 19*19*48
- 데이터 : 3천만수 (KGS 바둑 서버)
- 57% 정확도 달성 (바둑판 정 보만 인풋으로 쓸 때는 55.7% 정확도)
- GPU 50개로 3주간 학습
- 3억 4천만 step



2. Rollout Policy

- 빠른 시뮬레이션을 위한 작은 네트워크
- 인풋은 Hand-crafted features
- 네트워크는 linear softmax
- 정확도는 24.2%
- · 대신 action을 한번 선택하는 데 필요한 시간은 2μs (SL Policy는 3 ms)

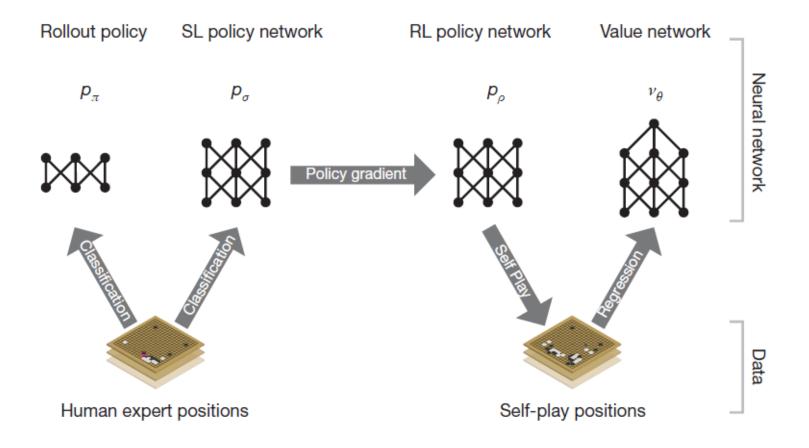


3. RL Policy

- SL Policy 와 동일한 형태의 네트워크
- 먼저 SL Policy의 weight로 초 기화
- 리워드는 게임이 끝나는 시점 에서만 주워지며, 이기면 +1, 지면 -1
- 알고리즘은 REINFORCE 알고 리즘 사용

$$\Delta
ho \propto rac{\partial \log p_{
ho}(a_t|s_t)}{\partial
ho} z_t$$

- RL vs SL ? RL 80% win
- GPU 50개로 1일간 학습

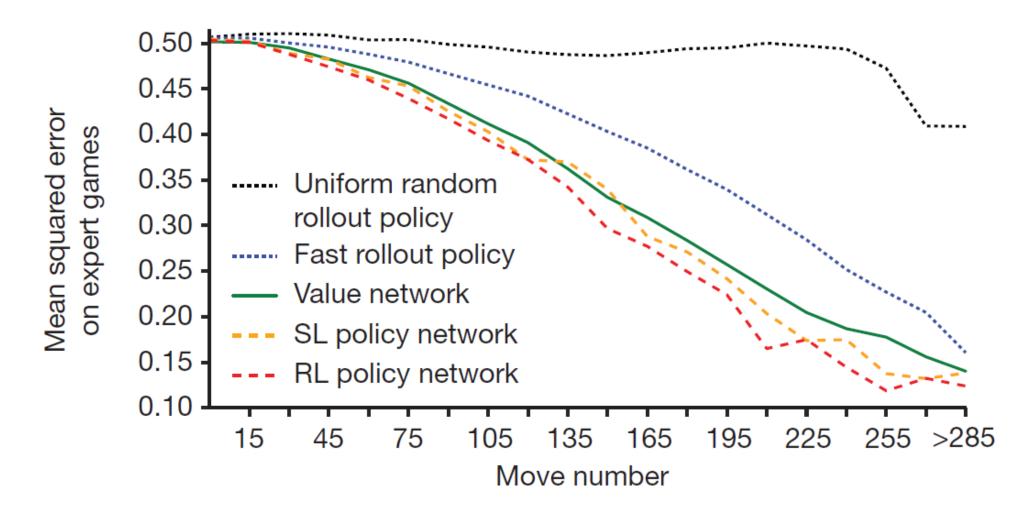


4. Value Network

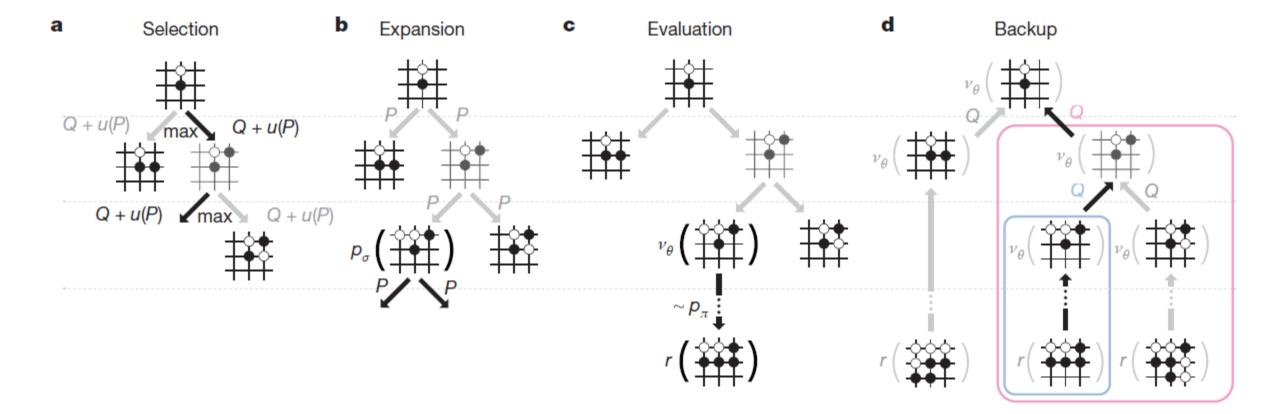
RL policy를 따랐을 때에 누가 이길지 예측하는 네트워크

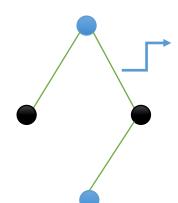
$$v^p(s) = \mathbb{E}[z_t|s_t = s, a_{t...T} \sim p]$$

- 아랫단은 SL 네트워크와 동일 하나 윗단이 single output.
 3천만 개의 상황으로부터 학
- 3천만 개의 상황으로부터 힉 습 (각각 다른 게임)
- GPU 50개로 1주일간 학습
- 5천만 mini-batch



• RL polic를 이용한 rollout 보다 1만5천배 빠른데, 비슷한 정확도를 보임





For each Edge...

Q(S,A): Action Value

N(S,A): Visit Count

P(S,A): Prior probability

$$a_t = \underset{a}{\operatorname{argmax}} \left(Q(s_t, a) + \underline{u(s_t, a)} \right)$$

$$Q(s,a) = \frac{1}{N(s,a)} \sum_{i=1}^{n} \mathbf{1}(s,a,i) \frac{V(s_L^i)}{V(s_L^i)} \qquad u(s,a) \propto \frac{P(s,a)}{1+N(s,a)}$$

$$V(s_L) = (1 - \lambda)\underline{v_{\theta}(s_L)} + \lambda\underline{z_L}$$

Value Network 롤아웃으로 게임을 끝까지 플레이 했을 때의 결과